# Tests sur la proportion

#### Mohamed LEMDANI

MISO Université de Lille

27 Septembre 2021

Cas d'une seule population Cas de deux populations Théorie Exemple

#### Test à un échantillon (observé/théorique)

Variable qualitative (binaire) étudiée sur une seule population (représentée par un échantillon de taille n)  $\Longrightarrow$  comprendre/tester cette population pour cette variable.

- Prévalence d'une maladie, sur une région : comparer à une valeur minimale.
- Logiciel de randomisation : comparer la proportion des sujets d'un bras à 50%.

Méthodologie: comparer la valeur d'une proportion (observée) dans la population dont est issu l'échantillon à une valeur donnée (théorique).

**Notations** :  $\pi$  = valeur de la proportion dans la population, p = valeur (calculée) sur

l'échantillon et  $\pi_0$  = valeur théorique (connue) à laquelle on compare  $\pi$ .

Hypothèses :  $H_0$  :  $\{\pi = \pi_0\}$  contre  $H_1$  :  $\{\pi \neq \pi_0\}$  (cas bilatéral) ou  $\{\pi <> \pi_0\}$  (unilatéral). **Données**: n observations de  $X \Longrightarrow x_1 = A, x_2 = B, ..., x_n = A \Longrightarrow p = n_A/n$ .

 $\label{eq:Variable de décision} \mbox{Variable de décision}: u = \frac{p - \pi_0}{\sqrt{\frac{\pi_0(1 - \pi_0)}{n}}} \sim \mathcal{N}(0, 1) \mbox{ sous } H_0.$  Conditions d'utilisation :

- n "grand" (n ≥ 30) et
- $\pi_0$  "ni trop petite" ( $n\pi_0 \ge 5$ ) "ni trop grande" ( $n(1-\pi_0) \ge 5$ ).

Choix de  $\alpha$  et construction des zones d'acceptation/rejet à partir de la table de la N(0,1).

#### Exemple 1

Un logiciel simulant le jeu de "pile" ou "face" a été conçu afin de randomiser des groupes dans le cadre d'essais cliniques. Afin de le tester, on simule  $10\,000$  lancers qui retournent un total de 5110 "piles". Peut-on dire que ce logiciel simule une pièce truquée au seuil de  $5\,\%$ ?

Variable observée : X = "Résultat du lancer", observée sur un échantillon de taille  $n = 10\,000$ .

 $\pi = \mathbb{P}(X = \text{"pile"})$  ou proportion de "piles" sur la "population".

$$\pi_0 = 1/2$$
 (pièce non truquée).

$$\begin{array}{ll} H_0: \{\pi=1/2\} & \textit{versus} & H_1: \{\pi\neq 1/2\}. \\ \textbf{Variable de décision}: u = \frac{p-\pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{p}}} \sim \mathcal{N}(0,1) \; \text{sous} \; H_0. \end{array}$$

#### Conditions:

- $n = 10000 \ge 30 \sqrt{.}$
- $n\pi_0 = 10\,000 \times (1/2) = 5\,000 \geqslant 5$  et  $n(1-\pi_0) = 10\,000 \times (1/2) = 5\,000 \geqslant 5$   $\sqrt{.}$

Cas d'une seule population Cas de deux populations Théorie Exemple

#### Exemple 1 (suite)

### **Calculs**: p = 5110/10000 = 0.511

$$\Rightarrow u_c = \frac{0.511 - 0.5}{\sqrt{\frac{0.5(1 - 0.5)}{10000}}} = \frac{0.011 \times \sqrt{10000}}{\sqrt{0.5^2}} = 1.1/0.5 = 2.2.$$

**Zone de non-rejet (** $\alpha = 5\%$ **)** :  $\mathfrak{u}_c \notin [-1.96, 1.96] \Longrightarrow$  rejet de  $H_0$  au seuil de 5% (au risque de 5%, on peut conclure que le logiciel simule une pièce truquée).  $G(\mathfrak{a}) = 0.025 \Longrightarrow \mathfrak{a} = 1.96$ 

Calcul de la p-value : Rejet à 
$$5\%$$
  $\Longrightarrow$  rejet pour tout  $\alpha > 5\%$ .

Pour quel  $\alpha$  minimal peut-on rejeter? C'est la p-value (niveau de signification) p du test.

$$p = 2 \times G(2.2) \approx 2 \times 0.014 = 0.028 = 2.8\%.$$

### Comparaison de deux proportions observées

Variable qualitative (binaire) X étudiée sur deux populations représentées, chacune, par un échantillon (tailles respectives  $n_1$  et  $n_2$ )  $\Longrightarrow$  comparer des proportions de X entre ces populations.

- comparer les taux d'efficacité de deux médicaments,
- comparer le taux de présence d'un caractère entre deux populations.

Paramètres étudiés : proportions d'une valeur A de X sur les populations ( $\pi_1$  et  $\pi_2$ ).

Objectif : Comparer ces deux paramètres

$$\begin{aligned} & \text{Hypoth\`eses}: H_0: \{\pi_1 = \pi_2\} \text{ contre } H_1: \{\pi_1 \neq \pi_2\} \text{ (cas bilat\'eral), } \{\pi_1 <> \pi_2\} \text{ (unilat\'eral).} \\ & \textbf{Variable de d\'ecision}: u = \frac{p_1 - p_2}{\sqrt{\frac{p(1-p)}{n_1} + \frac{p(1-p)}{n_2}}} \sim \mathcal{N}(0,1) \text{ sous } H_0. \end{aligned}$$

 $v_1, v_2$ : proportions respectives calculées sur les deux échantillons.

p : proportion commune (calculée sur le regroupement des deux échantillons).

Conditions d'utilisation :

- $n_1$  et  $n_2$  "grands" ( $\geqslant 30$ ) et
- p "ni trop petite"  $(n_1p, n_2p \ge 5)$  "ni trop grande"  $(n_1(1-p), n_2(1-p) \ge 5)$ .

# Théorie Exemple

#### Exemple

Exemple 2 : On souhaite comparer l'effet d'un traitement à celui d'un placebo. Pour cela, on randomise 100 sujets en deux bras paritaires. À l'issue de l'étude, on constante une amélioration pour 30 patients traités contre 20 patients placebo. Peut-on dire que le traitement est plus efficace que le placebo au seuil de 5%?

Variable observée : X = "Amélioration" (oui/non), observée sur deux échantillons de tailles  $n_1 = n_2 = 50$  (1= 'Traités' et 2 = 'Placebos').

**Données**: 
$$p_1 = \frac{30}{50} = 0.6$$
,  $p_2 = \frac{20}{50} = 0.4$  et  $p = \frac{30+20}{50+50} = \frac{50}{100} = 0.5$  et  $1 - p = 0.5$ .

$$H_0: \{\pi_1=\pi_2\} \qquad \textit{versus} \qquad H_1: \{\pi_1>\pi_2\}.$$

Variable de décision : 
$$u = \frac{p_1 - p_2}{\sqrt{\frac{p(1-p)}{n_1} + \frac{p(1-p)}{n_2}}} \sim \mathcal{N}(0, 1)$$
 sous  $H_0$ .

### Conditions:

• 
$$n_1 = n_2 = 50 \ge 30 \sqrt{.}$$

• 
$$n_1p = n_2p = n_1(1-p) = n_2(1-p) = 50 \times 0.5 = 25 \ge 5 \sqrt{.}$$

# Cas d'une seule population Cas de deux populations

Théorie Exemple

#### Exemple 2 (suite)

$$H_0: \{\pi_1 = \pi_2\} \qquad \textit{versus} \qquad H_1: \{\pi_1 > \pi_2\}.$$

$$p_1 = 0.6, p_2 = 0.4 \text{ et } p = 1 - p = 0.5.$$

$$u = \frac{p_1 - p_2}{\sqrt{\frac{p(1-p)}{n} + \frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1) \text{ sous } H_0.$$

Zone de rejet (unilatérale, 
$$\alpha=5\%$$
) :  $u_c \in [1.6449, +\infty[$ .

rejet  $\Longrightarrow$  choix de  $H_1 \Longrightarrow \pi_1 > \pi_2 \Longrightarrow \mathfrak{p}_1 > \mathfrak{p}_2 \Longrightarrow \mathfrak{u} > 0$  (zone de rejet du côté de  $+\infty$ ).

$$G(\alpha)=0.05\Longrightarrow \alpha=1.6449.$$

$$\textbf{Calculs}: u_c = \frac{0.6 - 0.4}{\sqrt{\frac{0.5 \times 0.5}{50} + \frac{0.5 \times 0.5}{50}}} = \frac{0.2}{\sqrt{0.5^2/25}} = \frac{0.2 \times 5}{0.5} = 2.$$

Rejet de H<sub>0</sub> au seuil de 5% (on seuil de 5% on peut conclure à un traitement plus efficace que le placebo).

Niveau de signification (p-value) :

$$p = G(2) \approx 0.023(2.3\%).$$